



Wissam BENHADDAD

Senior Data Science & AI Engineer | Spécialiste en IA Générative

📍 Paris, France ✉️ wissam.benhaddad.pro@gmail.com ☎️ 06 17 93 45 70
🌐 [wissam-benhaddad-a7a090137](https://www.linkedin.com/in/wissam-benhaddad-a7a090137) 🔄 Wissben

Résumé

Ingénieur Senior Data Science & IA avec plus de 6 ans d'expérience dans la conception et la mise en production de systèmes IA à haute valeur ajoutée. Spécialisé dans les Grands Modèles de Langage (LLM), l'IA Générative et les pipelines ML de bout en bout — du fine-tuning et des architectures RAG jusqu'à l'inférence en temps réel sur AWS et Azure. A piloté la conception et la livraison de solutions d'intelligence documentaire, de frameworks de fine-tuning LLM et de systèmes IA agentiques dans des secteurs variés tels que l'assurance, le juridique et les médias. Reconnu pour allier une expertise technique approfondie à une capacité à fédérer les parties prenantes, transformant des opportunités IA complexes en résultats business mesurables.

Expérience Professionnelle

Ekimetrics (Client - BPCE-Vie), Consultant Data Science

Paris, France

Sep 2025 – actuellement

- Intégré au sein de l'équipe Data Science interne pour façonner les initiatives stratégiques en IA, traduisant les défis métiers en cas d'usage actionnables et établissant une feuille de route complète de stratégie data
- Conçu et défendu une feuille de route de transformation entièrement pilotée par l'IA pour le département Financier, englobant l'amélioration de la gouvernance des données, le déploiement d'un chatbot intelligent et des pipelines d'analyse documentaire automatisés pour rationaliser les workflows opérationnels
- Collaboré avec les parties prenantes transverses pour prioriser les opportunités IA à fort impact, équilibrant faisabilité technique et valeur métier pour générer des gains d'efficacité mesurables
- Stack Technique:** Python, GCP, Agentic GenAI, Traitement Documentaire, IA Conversationnelle, Talk to Data, LangGraph

Ekimetrics, Data Scientist Senior — GenAI / Recherche Appliquée (LLMs)

Paris, France

Juil 2024 – Sep 2025

- Piloté la transition de la R&D vers la livraison pour le fine-tuning de LLM, transformant des cas d'usage ambigus en feuille de route priorisée avec des métriques de succès claires et des jalons livrables
- Construit un guide méthodologique de bout en bout pour le fine-tuning (curation de données, recettes d'entraînement, harnais d'évaluation, directives de déploiement) pour rendre les résultats reproductibles et orientés production
- Dirigé les choix techniques (SFT/PEFT, compromis architecturaux, stratégie d'évaluation) et animé des revues avec les parties prenantes seniors pour dé-risquer la portée, les coûts et les délais
- Devenu le conseiller de référence pour le fine-tuning de LLM au sein des équipes, débloquent les projets en combinant conseils techniques approfondis et plans de livraison pragmatiques
- Stack Technique:** Python, SQL, Databricks, PyTorch, Hugging Face, Docker, Git

Ekimetrics (Mission Client), Extraction de KPI depuis Documents Non-Structurés (Client Confidentiel)

Paris, France
Mar 2025 – Sep 2025

- Livré une approche délimitée et prête pour la production pour l'extraction automatisée de KPI, alignant les parties prenantes sur les définitions, critères d'acceptation et cibles de qualité mesurables
- Conçu un pipeline robuste de compréhension documentaire (RAG, découpage sémantique, désambiguïsation) axé sur la traçabilité et des outputs cohérents
- Construit la confiance des parties prenantes en traduisant le comportement des modèles en reporting décisionnel clair (modes de défaillance, compromis, recommandations de déploiement)
- **Stack Technique:** Azure OpenAI, Databricks, Document AI, Python

Ekimetrics (Mission Client - CNP Assurances), Adoption & Gouvernance GenAI — Microsoft Copilot

Paris, France
Nov 2024 – Mar 2025

- Animé des ateliers de découverte pour traduire les points de douleur métiers en backlog GenAI priorisé (impact vs. faisabilité), permettant une livraison rapide et orientée résultats
- Livré et documenté plus de 40 cas d'usage Copilot à forte valeur ajoutée (résumés, extraction de KPI, tableaux de bord, comptes-rendus de réunions) avec des garde-fous clairs et des recommandations d'adoption
- Créé un framework de livraison reproductible (patterns de prompts, checklist de validation, recommandations de gouvernance) utilisé comme référence par les équipes client et internes
- Piloté l'accompagnement en formant les parties prenantes, capturant les leçons apprises et améliorant l'adoption en rendant les outputs fiables et faciles à opérationnaliser
- **Stack Technique:** MS365 Copilot, Copilot Studio, Copilot Agents

Ekimetrics, Data Scientist Senior — GenAI / Recherche Appliquée (LLMs)

Paris, France
Juil 2024 – Déc 2025

- Piloté la transition de la R&D vers la livraison pour le fine-tuning de LLM, transformant des cas d'usage ambigus en feuille de route priorisée avec des métriques de succès claires et des jalons livrables
- Construit un guide méthodologique de bout en bout pour le fine-tuning (curation de données, recettes d'entraînement, harnais d'évaluation, directives de déploiement) pour rendre les résultats reproductibles et orientés production
- Dirigé les choix techniques (SFT/PEFT, compromis architecturaux, stratégie d'évaluation) et animé des revues avec les parties prenantes seniors pour dé-risquer la portée, les coûts et les délais
- Devenu le conseiller de référence pour le fine-tuning de LLM au sein des équipes, débloquent les projets en combinant conseils techniques approfondis et plans de livraison pragmatiques
- **Stack Technique:** Python, SQL, Databricks, PyTorch, Hugging Face, Docker, Git

Ekimetrics (Mission Client - Groupe Crystal), Segmentation Client & Scoring

Paris, France
Août 2024 – Jan 2025

- Livré des recommandations de segmentation et scoring fondées sur une EDA rigoureuse et une validation de la qualité des données pour garantir des conclusions fiables
- Piloté la livraison de la feuille de route à l'exécution (planification, rituels sprint, revues parties prenantes), maintenant la portée étroitement alignée aux décisions métiers
- Communiqué des résultats actionnables (prochaines étapes, compromis attendus, risques) aux parties prenantes techniques et non-techniques
- **Stack Technique:** Python, SQL, Databricks, Scikit-learn, Azure, Jira

ByLaw, Data Scientist Senior

- Construit et déployé une solution de production d'extraction documentaire utilisant des transformers multi-modaux pour automatiser la compréhension des bulletins de paie pour les workflows de rémunération
- Industrialisé l'extraction basée sur LLM à travers des documents hétérogènes (contrats, rapports juridiques et financiers) avec un focus sur la fiabilité et la qualité mesurable
- Renforcé le pipeline MLOps à travers des revues de code, corrections de bugs et durcissement du déploiement pour assurer des releases fluides et une inférence stable
- Déployé et opéré des modèles sur AWS SageMaker pour l'inférence temps réel, améliorant l'efficacité de traitement de bout en bout et la maintenabilité
- Contribué à la montée en charge de l'équipe en recrutant et mentorant des data scientists à travers des revues et des conseils techniques
- **Stack Technique:** Python, SQL, AWS SageMaker, PyTorch, Hugging Face, Docker, Git

Paris, France
Juin 2023 – Juil 2024

Qwarry, Lead Data Scientist

- Exploré des offres publicitaires basées sur le retail media, conduisant à des solutions innovantes pour améliorer les produits de l'entreprise
- Développé des modèles ML avancés et les ai intégrés dans les produits et services de l'entreprise
- Mentoré des data scientists juniors, fournissant des conseils techniques et favorisant leur croissance professionnelle
- Présenté les résultats de recherche ML aux parties prenantes, guidant les décisions métiers éclairées
- **Stack Technique:** AWS SageMaker, Tableau, Python, Pandas, Jira, Trello, Asana

Paris, France
Jan 2023 – Juin 2023

Qwarry, Data Scientist

- Implémenté et amélioré des modèles de classification de texte dans l'environnement AWS SageMaker, améliorant l'efficacité du traitement des données
- Établi un pipeline ML CI/CD utilisant AWS SageMaker pipelines et GitHub actions, rationalisant le processus de déploiement
- Conçu et implémenté des solutions de ciblage socio-démographique utilisant des modèles Machine Learning, optimisant les stratégies de segmentation d'audience
- Configuré et déployé des solutions d'annotation de données textuelles utilisant LabelStudio, améliorant l'efficacité de l'annotation
- Réalisé des analyses de contenu web à grande échelle utilisant PySpark dans un environnement cloud, extrayant des insights actionnables
- Généré des tableaux de bord et rapports informatifs sur les données socio-démographiques, permettant des stratégies data-driven
- **Stack Technique:** AWS SageMaker, GCP Big Query, PySpark, Python, Pandas, Git, Docker, Jira, Trello

Paris, France
Sep 2020 – Déc 2022

Qwarry, Stagiaire Data Scientist

- Développé une boîte à outils machine learning en Python, rationalisant les processus de développement de modèles
- Organisé et validé des datasets pour des tâches de classification de texte, assurant la qualité et la pertinence des données
- Construit et déployé des modèles ML pour la classification de texte derrière une API Django, améliorant les capacités d'analyse textuelle
- **Stack Technique:** Keras, TensorFlow, Python, Pandas, Django, SQL

Paris, France
Mar 2020 – Aoû 2020

Formation

MS **Université Paris Descartes**, Machine Learning pour la Data Science

Paris, France
Sep 2019 – Juin 2020

MS **Université des Sciences et de la Technologie**, Systèmes Informatiques Intelligents

Alger, Algérie
Sep 2017 – Juin 2019

Projets Personnels

Speact

Jan 2019 – Déc 2019

Projet de reconnaissance vocale pour développer un assistant de manipulation informatique utilisant la classification d'intentions et la gestion de dialogue

- Développé les composants backend et frontend pour un assistant informatique à commande vocale
- Implémenté un pipeline NLU avec classification d'intentions et gestion de dialogue
- Appliqué l'apprentissage par renforcement pour les capacités d'assistant personnel intelligent
- **Stack Technique:** Python, Keras, Pandas, NLTK, Reinforcement Learning

El-Muaiyen

Jan 2018 – Déc 2018

Application web pour la gestion d'un dictionnaire historique de la langue arabe

- Construit une application web full-stack avec frontend moderne et backend RESTful
- Implémenté une fonctionnalité de recherche utilisant Elasticsearch pour une récupération de texte efficace
- Déployé sur Google Cloud Platform utilisant Docker et Kubernetes
- **Stack Technique:** Vue.js, Vuetify, Django, Django Rest Framework, Docker, Kubernetes, GCP, NLTK, Elasticsearch

Compétences

Langages de Programmation: Python, SQL, R, C/C++, Java, JavaScript

GenAI & LLMs: Fine-tuning de LLM (PEFT, LoRA, QLoRA), Pipelines RAG, Prompt Engineering, RLHF, LangChain, LlamaIndex, Modèles d'Embeddings, Évaluation de Modèles

Frameworks ML/DL: PyTorch, TensorFlow, Hugging Face Transformers, Scikit-learn, Keras, NumPy, Pandas, NLTK, spaCy

MLOps & Production: Docker, Kubernetes, MLflow, Pipelines CI/CD, Monitoring de Modèles, GitHub Actions, Prefect, Git

Cloud & Infrastructure: AWS (SageMaker, S3, EC2, Lambda), Azure (OpenAI, ML), GCP (Big Query), Databricks, Terraform

Bases de Données Vectorielles & Recherche: Pinecone, ChromaDB, FAISS, Elasticsearch, Recherche Sémantique

Data Engineering: PySpark, Big Query, Databricks, SQL, Pipelines de Données, ETL

Déploiement IA & APIs: FastAPI, Flask, Django, APIs REST, Model Serving, Inférence Temps Réel

IA Spécialisée: Document AI, Transformers Multi-modaux, NLU, Classification de Texte, Computer Vision, IA Agentique

Langues

Français: Langue maternelle

Anglais: Compétence professionnelle complète

Arabe: Langue maternelle

Centres d'Intérêt

- Randonnée et activités outdoor
- Football
- Lecture et Manga
- Musique